Tecnológico de Monterrey

Actividad 3

Análisis predictivo

Análitica de datos y herramientas de inteligencia artificial

09 de octubre de 2026

Ximena Dessire Salazar Garcia | A01737088

Arantza Sarai Perez Jimenez | A01738004

Rodrigo Zapien Barrios | A01424400

Rodrigo Ocampo | A01752337

Daniela Pérez Lugo | A01735108

El presente reporte presenta el análisis de regresión lineal simple y múltiple realizado sobre la base de datos de la empresa CLV México. El objetivo fue: (1) preprocesar la base, tratando nulos y atípicos, y haciendo transformaciones, (2) medir la correlación entre las variables cuantitativas y obtener los modelos simples de mayor correlación, y (3) finalmente, construir el mejor modelo múltiple para dos variables cuantitativas y realizar la comparación con los resultados del mapa de calor.

'Negocios_CRM'

Esta sección presenta el análisis de regresión lineal realizado sobre la base de datos llamada 'Negocios_CRM' con un total de 5268 registros y 20 columnas con información de cada oportunidad comercial.

Variables utilizadas:

Variable	Tipo	Rol en el análisis
valor_negocio	Cuantitativa continua	Monto del negocio. Se usa su logaritmo (log_valor) como variable dependiente Y1
valor_previsto	Cuantitativa continua	Descartada: es idéntica a valor_negocio
numero_actividades	Cuantitativa discreta (conteo)	Variable dependiente Y2 y predictora
dias_cierre	Cuantitativa (construida)	Días entre fecha_creacion y fecha_cierre; predictora
tipo_negocio, nombre_zona	Categóricas	Convertidas en variables dummy del modelo múltiple
nombre_pipeline	Categórica	Convertida en una variable binaria (pipeline_secundario)
estado, vendedor	Categóricas	Probadas y descartadas por traslape con la zona
nombre_etapa	Categórica	Define qué negocios se consideran ganados

En la etapa de preprocesamiento, se observó que las columnas de dinero y de número de actividades venían como texto, por lo que se convirtieron a numéricas. Esa conversión reveló 23 registros con columnas desfasadas: en 21 el *valor_negocio* ya venía vacío en el archivo original y en 2 contenía un nombre de persona en lugar de un monto; en varios de ellos *numero_actividades* traía una fecha. Estos registros quedaron fuera del análisis al exigir un monto mayor a 0.

Sumado a eso, al inicio se supuso que los ceros de *valor_negocio* correspondían a negocios perdidos o abiertos. El cruce con la etapa mostró lo contrario: la mayoría de los

negocios ganados tiene valor 0, es decir, el cero casi siempre significa monto no registrado y no una venta de cero pesos.

Si se hubieran conservado los ceros, la regresión mezclaría dos fenómenos distintos y la pendiente quedaría sesgada hacia cero. Filtrar solo por monto mayor a 0 tampoco era suficiente, porque habría incluido 231 negocios perdidos o abiertos. Por eso el conjunto de análisis principal son los negocios en etapa Cierre Ganado o Ganado con monto mayor a 0, con un total de 669 negocios.

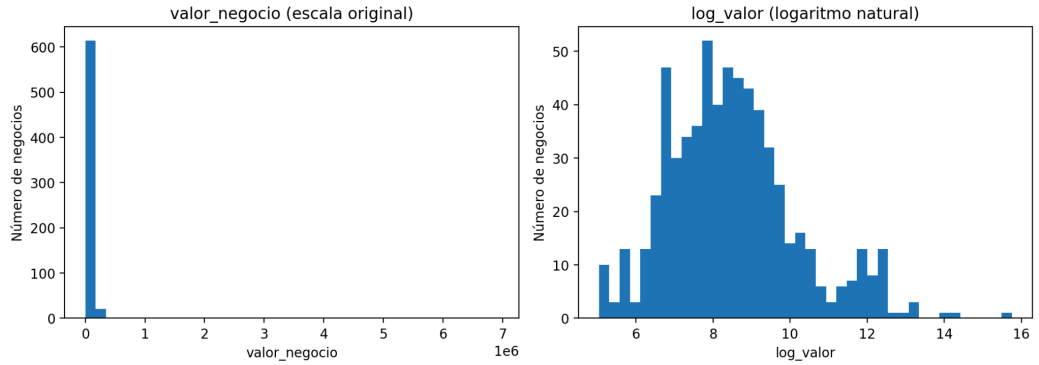
En los 900 negocios con monto, *valor_previsto* es exactamente igual a *valor_negocio*. Se descartó como variable predictora para evitar fuga de información.

La variable *dias_cierre* se construyó restando *fecha_creacion* a *fecha_cierre*. En toda la base hay 115 nulos y 2,085 valores negativos, lo que indica que *fecha_cierre* no siempre es la fecha real de cierre, incluso podría ser una fecha esperada. Entre los 669 negocios ganados con monto hubo 24 valores negativos y 3 nulos, que se excluyeron para los modelos que usan esta variable.

También se aplicó el método del rango intercuartílico (IQR) sobre los 642 negocios.

Variable	Q1	Q3	IQR	Límite inferior	Límite superior	Atípicos
valor_negocio	1,546.54	11,534.48	9,987.94	−13,435.36	26,516.40	91 (14.2%)
numero_actividades	0	1	1	−1.5	2.5	54 (8.4%)
dias_cierre	0	4.75	4.75	−7.12	11.88	99 (15.4%)

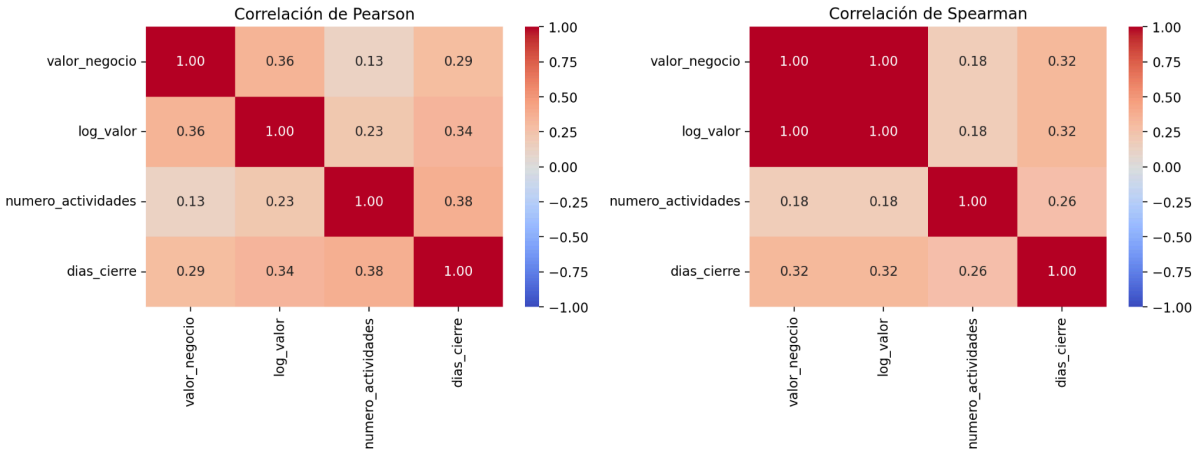
El monto tiene un sesgo de 21.21. Los atípicos de *valor_negocio* son montos legítimos, por lo que no se eliminaron: se aplicó el logaritmo natural (log_valor), que redujo el sesgo a 0.73. En *numero_actividades* y *dias_cierre* el IQR es muy pequeño porque la mayoría de los valores está en 0, así que marcar atípicos es esperable y tampoco se eliminaron.



Al repetir el modelo de *log_valor* contra *numero_actividades* sin los 21 atípicos de *log_valor*, la pendiente pasó de 0.2737 a 0.2181 y el R^2 de 0.0512 a 0.0407. Cambia la magnitud pero no la conclusión (relación positiva y débil), por lo que se conservaron todos los datos.

Para el modelo múltiple se agruparon las categorías con menos de 30 negocios en la categoría ‘Otro’. El pipeline tiene una categoría de solo 7 negocios, por lo que se creó una variable binaria que marca el segundo pipeline más grande, dejando los 7 junto al principal. En todas las variables dummy la categoría de referencia es la más frecuente.

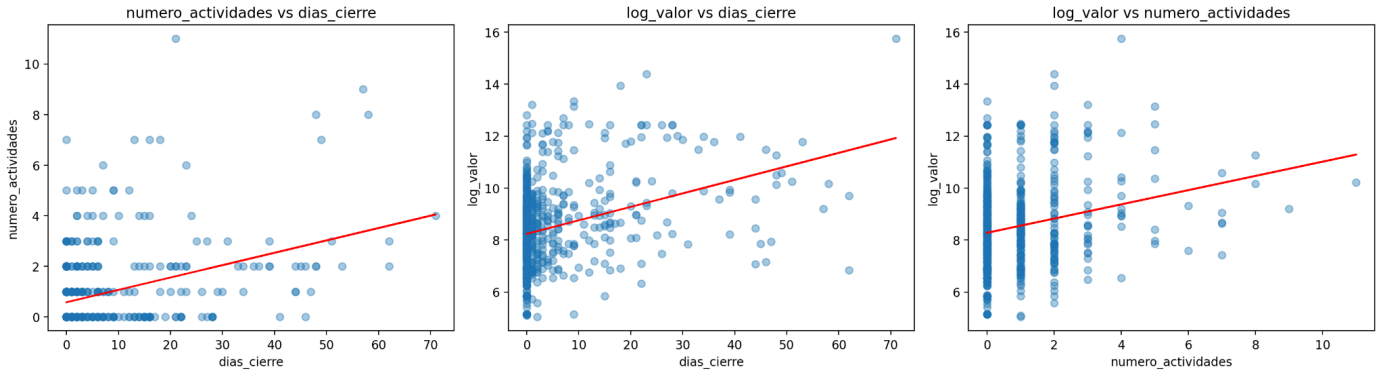
Análisis de correlación



Al calcular la correlación de Spearman, *valor_negocio* y *log_valor* resultan idénticos (r= 1.00), mostrando una relación de 0.18 con *numero_actividades* y de 0.32 respecto a *dias_cierre*; la asociación entre *numero_actividades* y *dias_cierre* es de 0.26.

Modelo de regresión lineal simple

Modelo	Ecuación	r	R^2	p-valor
Actividades vs días de cierre	numero_actividades = 0.581 + 0.0489 × dias_cierre	0.383	0.147	7.4e-24
Monto vs días de cierre	log_valor = 8.2405 + 0.0519 × dias_cierre	0.337	0.113	1.8e-18
Monto vs actividades	log_valor = 8.2806 + 0.2737 × numero_actividades	0.226	0.051	6.6e-9



Tras el análisis, se interpreta lo siguiente:
• El modelo de mayor correlación es de actividades y días de cierre; cada 20 días adicionales equivalen aproximadamente a una actividad más (1 / 0.0489 ≈ 20.4).
• Por parte del monto y días de cierre, como el monto está en logaritmo, cada día adicional se asocia con un monto cerca de 5.3% mayor (e^0.0519 ≈ 1.053). La mayoría de los negocios cierra en menos de 5 días y el máximo es 71, por lo que no conviene extrapolar más allá de ese rango.
• En cuanto a monto y actividades; cada actividad adicional se asocia con un monto entre 24% y 31% mayor (según se incluyan o no los atípicos).
• Las tres pendientes son estadísticamente distintas de cero, pero los R^2 (5% a 15%) muestran que ninguna variable explica por sí sola gran parte de la variación.

Justificación de las correlaciones

Estas explicaciones son hipótesis apoyadas en el mapa de calor y en el contexto comercial, por lo que se debe tener en mente que una correlación no demuestra causalidad.

Hablando inicialmente de actividades y días de cierre (0.38), un negocio que permanece más tiempo abierto acumula más llamadas, reuniones y seguimientos, de modo que ambas variables miden la vida del negocio. El coeficiente se mantiene idéntico (0.0489) en el modelo múltiple, lo que respalda esta explicación.

Por parte del monto y días de cierre (0.34), los negocios de mayor monto suelen requerir cotización, negociación y aprobaciones, por lo que tardan más en cerrar.

Además, observamos que en el rubro de monto y actividades (0.23), a los negocios más grandes se les dedica más seguimiento comercial. También podría ocurrir al revés, sin embargo, la base no permite distinguir la dirección.

En cuanto a las diferencias por segmento, encontramos que el modelo muestra que el pipeline, la zona y el tipo de cliente explican gran parte de la variación, es decir, parte de lo que muestra el mapa de calor se debe a que ciertos segmentos son a la vez más lentos, más activos y de mayor monto.

Regresión lineal múltiple

Se construyó un modelo para cada una de dos variables cuantitativas: Y1 = *log_valor* y Y2 = *numero_actividades*. Las demás candidatas fueron las otras variables numéricas, la variable binaria de pipeline y las dummies de tipo de negocio y zona. La selección se hizo por eliminación, quitando una a una, iniciando con mayor p-valor hasta que todas queden con $p \leq 0.05$. Se verificó la multicolinealidad con el factor de inflación de la varianza (VIF).

El primer intento incluyó también estado y vendedor. Dio señales claras de multicolinealidad: la dummy de la zona Metropolitana y la del vendedor V5 resultaron idénticas (coeficientes iguales), y en el modelo de actividades varios VIF superaron 10. El cruce entre variables explica el motivo: cada vendedor trabaja prácticamente una sola zona y cada estado pertenece a una zona. El efecto de un vendedor o de un estado no se puede separar del de su zona, así que se dejaron fuera y se conservó la zona.

Modelo	R^2 ajustado con estado y vendedor	R^2 ajustado final
log_valor	0.360	0.307
numero_actividades	0.547	0.521

La pérdida de capacidad explicativa es pequeña y a cambio los coeficientes son interpretables. En el modelo final todos los VIF son de 2.05 o menos.

Modelo final para Y1 = *log_valor*

n = 642 · 9 predictoras · R^2 = 0.317 · R^2 ajustado = 0.307 · p del estadístico F = 4.8e-47 · Durbin-Watson = 2.03

Predictora	Coeficiente	Efecto sobre el monto
Constante	7.5705	Monto típico de la categoría de referencia ≈ 1,940
número actividades	0.2596	+29.7% por cada actividad
días cierre	0.0343	+3.5% por cada día
pipeline secundario	−0.5867	−44.4% frente al pipeline principal
tipo negocio: Cliente nuevo	1.2476	≈ 3.5 veces el monto de la categoría de referencia
Zona Bajío	1.1569	≈ 3.2 veces (frente a Sureste Golfo)
Zona Noreste	1.1476	≈ 3.1 veces
Zona Desconocido	0.9629	≈ 2.6 veces
Zona Occidente Pacífico	0.9431	≈ 2.6 veces
Zona Metropolitana	−0.7613	≈ 0.47 veces (53% menos)

Todas las predictoras tienen $p < 0.05$ (la mayoría $p < 0.01$). La zona de referencia es el Sur Este Golfo de México (la más frecuente).

Modelo final para Y2 = *numero_actividades*

n = 642 · 7 predictoras · R^2 = 0.526 · R^2 ajustado = 0.521 · p del estadístico F = 1.6e-98 · Durbin-Watson = 2.06

Predictora	Coeficiente	Interpretación
Constante	−0.7796	Valor teórico sin predictoras (sin interpretación práctica)

dias_cierre	0.0489	+0.049 actividades por día (≈ 1 cada 20 días)
log_valor	0.1310	+0.13 actividades por cada unidad de logaritmo del monto
pipeline_secundario	1.6375	+1.64 actividades frente al pipeline principal (el efecto más fuerte, t = 18.6)
Zona Occidente Pacífico	0.4625	+0.46 actividades frente a Sureste Golfo
Zona Bajío	−0.6530	−0.65 actividades
Zona Desconocido	−0.5885	−0.59 actividades
Zona Noreste	−0.3074	−0.31 actividades

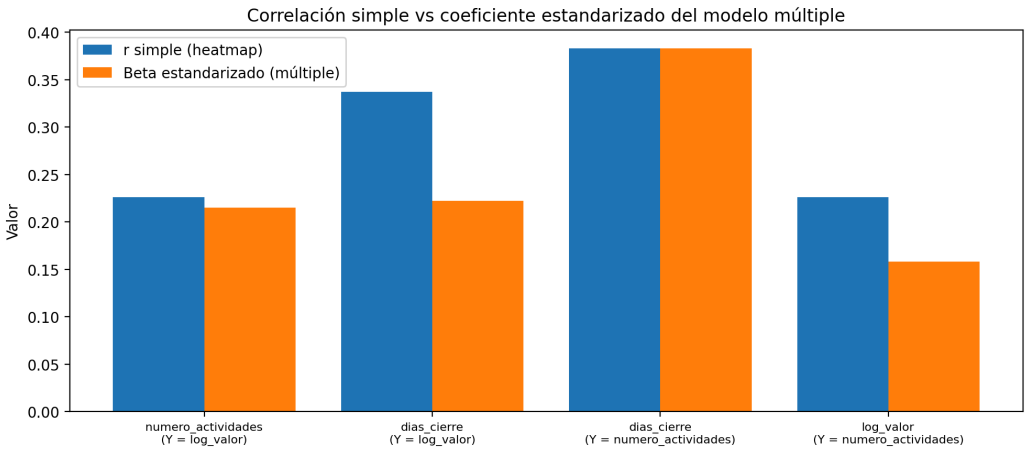
Comparación con el mapa de calor (regresión simple)

Para que el coeficiente múltiple sea comparable con la correlación del mapa de calor, se usa el **beta estandarizado** (el coeficiente expresado en desviaciones estándar).

Y	Predictora	r simple (heatmap)	Beta estandarizado (múltiple)
log_valor	numero_actividades	0.226	0.215
log_valor	dias_cierre	0.337	0.222
numero_actividades	dias_cierre	0.383	0.383
numero_actividades	log_valor	0.226	0.158

Tras la comparación se interpreta lo siguiente:

- Relaciones estables: *numero_actividades* con el monto casi no cambia (0.226 a 0.215) y *dias_cierre* con las actividades es idéntica (con el mismo coeficiente de 0.0489). Son las relaciones más sólidas.
- Relaciones que se debilitan: *dias_cierre* con el monto baja alrededor de un tercio (0.337 a 0.222) y el monto con las actividades pasa de 0.226 a 0.158. Parte de la correlación del mapa de calor provenía de que ciertos pipelines, zonas y tipos de cliente son a la vez más lentos, más activos y de mayor monto.
- Mejor explicación en conjunto: el R^2 sube de entre 0.05 y 0.15 en los modelos simples a 0.32 y 0.53 en los múltiples, principalmente por el pipeline, la zona y el tipo de negocio, variables que el mapa de calor no puede representar.



Conclusiones

La limpieza fue determinante, el 0 en el monto significa mayormente monto no registrado, y definir el conjunto ganado con monto (669 negocios) evitó un modelo sesgado. *valor_previsto* es idéntico a *valor_negocio* y se descartó para no inflar artificialmente el ajuste.

El logaritmo del monto corrigió un sesgo de 21.21 (a 0.73) y permitió usar regresión lineal.
La correlación más fuerte es entre actividades y días de cierre (r = 0.383, R^2 = 14.7%); con el monto, la mayor es la de días de cierre (r = 0.337).
Los modelos múltiples explican 31% (monto) y 52% (actividades) de la variación, gracias al pipeline, la zona y el tipo de negocio.

La relación entre actividades y días de cierre es la más robusta, y el segundo pipeline concentra más actividades pero con menores montos.
Se recomienda registrar siempre el monto en los negocios ganados y revisar la captura de fechas y columnas del CRM.

'Salidas de almacén'

Datos y variables

La base tiene 24,422 registros de salidas del Almacén General entre el 10-oct-2023 y el 3-sep-2026, de 35 marcas; el promedio es 4.59 salidas por registro (mediana 2, máximo 23).

Variable	Uso en el modelo	Razón
salidas	Dependiente (y)	Unidades que salen en cada registro
ano, mes, dia, dia_semana	Independientes numéricas	Derivadas de la fecha (dia_semana: 0 = lunes)

marca	Independiente, convertida a numérica	One-hot: 34 columnas 0/1, marca de referencia 3dgar; en el modelo simple, promedio de salidas por marca
nombre_almacen	Descartada	Un solo valor (Almacén General)
salidas_clase	Descartada	Es una categorización de la propia variable dependiente
articulo_id, clave_articulo, nombre_articulo	Descartadas	Son identificadores, no magnitudes

Regresión simple

La recta de salidas = 0.1483 × día + 1.8523 sigue la tendencia de fin de mes, pero solo explica 6.2 % de la variación (R^2 = 0.062, r = 0.248).



La recta suaviza el escalón del día 26: sobrestima los días 21 a 25 y subestima del 26 al 31. Un segundo modelo simple, con la marca codificada como su promedio de salidas, llega a R^2 = 0.099 (0.089 en datos de prueba): la marca explica más que cualquier variable de calendario.

Regresión múltiple

Agregar la marca duplica con creces el poder explicativo: el modelo B (fecha + marca) llega a R^2 = 0.159, contra 0.063 del modelo A (solo fecha).

Modelo A: año, mes, día, día de la semana. R^2 = 0.063 (r = 0.251). Casi todo el efecto viene del día del mes.

y = 0.2035\,x_1 + 0.0438\,x_2 + 0.1502\,x_3 + 0.0267\,x_4 - 410.59
donde x1 = año, x2 = mes, x3 = día del mes, x4 = día de la semana.

Modelo B: las mismas variables + marca (one-hot). $R^2 = 0.159$ ($r = 0.399$). Con división 80/20 el R^2 de prueba es 0.154 y el error absoluto medio es 3.43 salidas, así que no hay sobreajuste.

Variable	Coeficiente (salidas)
Intercepto	−242.93
dia	0.1513
anio	0.1194
dia_semana	0.0498
mes	0.0411
marca Full Arch	+12.07
marca Cutting Fluids	+9.62
marca Huge	+7.31
marca Apple	+6.46
marca Ipd	+6.41
marca Aidite	+4.86
marca Huawei	−1.79

Los coeficientes de marca son la diferencia en salidas esperadas frente a la marca de referencia (3dgar), con la fecha constante.

Comparación de modelos

La marca es la variable que más separa a los modelos; ninguno supera 16 % de variación explicada.

Modelo	Variables	R^2	Nota
Simple 1	día del mes	0.062	y = 0.1483x + 1.8523; r = 0.248
Simple 2	marca (promedio por marca)	0.099	0.089 en prueba (80/20)
Múltiple A	año, mes, día, día de la semana	0.063	r = 0.251
Múltiple B	fecha + marca (one-hot)	0.159	0.154 en prueba; error medio 3.43 salidas; r = 0.399

Conclusiones

- **Marca:** es el factor con más peso. Full Arch, Cutting Fluids, Huge, Apple, Ipd y Aidite tienen salidas esperadas entre 4.9 y 12.1 unidades por encima de la marca de referencia.
- **Fecha:** el día del mes es la única variable de calendario con efecto; las salidas suben hacia fin de mes (promedio de 2.3 el día 1 contra 6.8 el día 31). Año, mes y día de la semana casi no aportan.
- **Límite:** el mejor modelo explica 15.9 % de la variación. El resto depende de factores que no están en la base, como la demanda por artículo o las promociones.
- **Validación:** el R^2 de prueba (0.154) casi coincide con el de entrenamiento, así que el modelo B generaliza igual de bien que se ajusta.

Base: Ventas

Variables

La base Ventas tiene 114,501 líneas de venta, de enero de 2023 a septiembre de 2026.

Variables eliminadas

Variable	Motivo
Unnamed: 0, folio, folio_abreviado, articulo_id, clave_articulo, cp	Son identificadores o códigos: sus números no representan cantidades
nombre_articulo (3,895), nombre_cliente (4,743), ciudad (409), vendedor (139), estado (51), marca (34)	Son texto con demasiadas categorías y sin un orden de menor a mayor
precio_unitario, total_unidades, total_neto, fecha_documento	Se reemplazaron por su versión en categorías (tabla siguiente)

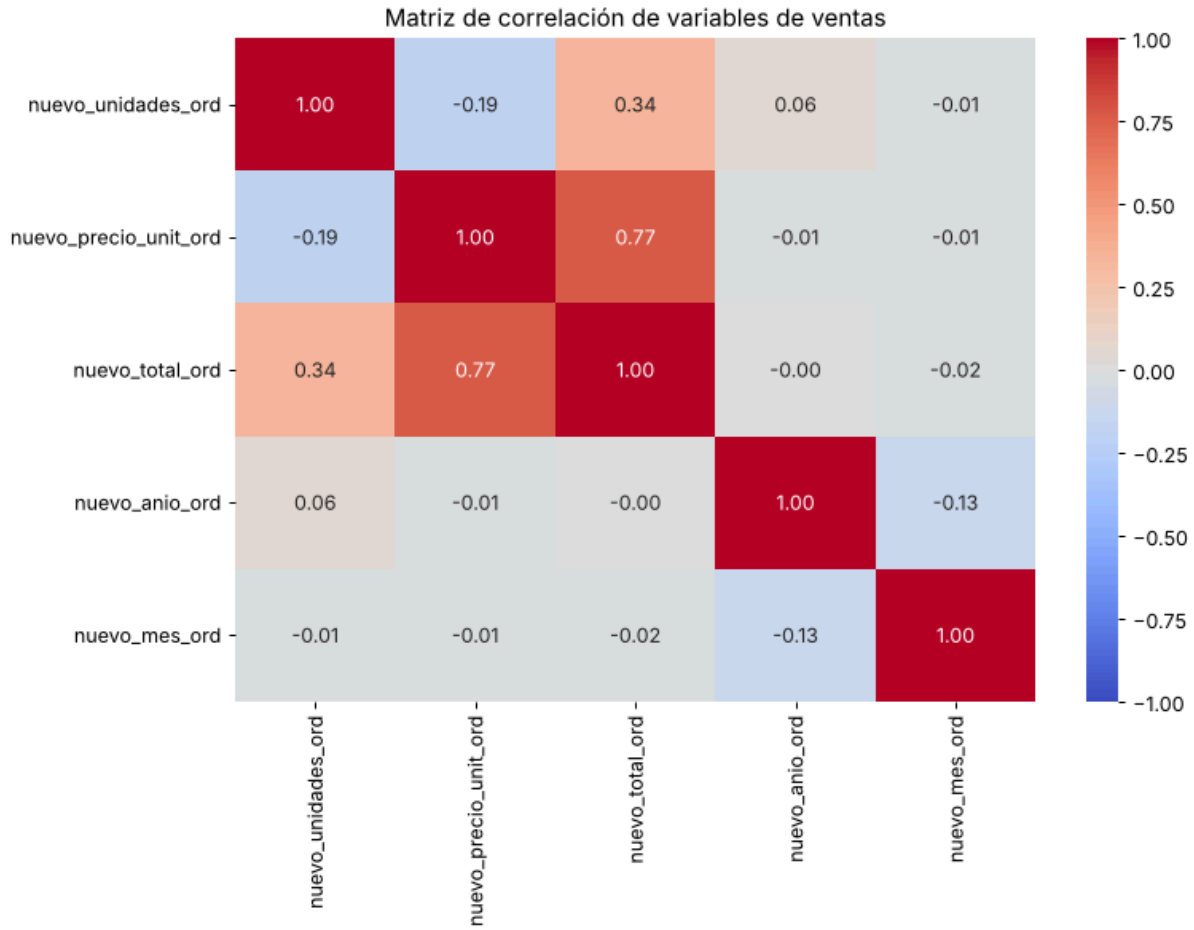
Variables utilizadas

Las variables numéricas se dividieron en categorías porque tienen valores extremos: en la misma base hay escáneres de más de $2 millones y dientes de $170. Las categorías van de la más baja a la más alta.

Variable original	Nueva variable	Categorías
total_unidades	Unidades	Unitaria (1), Par (2), Pocas (3–5), Mayoreo (6–250)
precio_unitario	Precio unitario	Muy económico (0–150.86), Económico (150.87–181.03), Medio (181.04–655.17), Alto (655.18–1,284.48), Premium (más de $1,284.48)
total_neto	Venta total	Mínima (0–172.41), Baja (172.42–383.62), Media (383.63–982.76), Alta (982.77–2,327.59), Top (más de $2,327.59)
fecha_documento	Año	2023, 2024, 2025, 2026 (solo enero a septiembre)
fecha_documento	Mes	1 a 12

Las categorías de precio y de venta total son quintiles: cada una agrupa alrededor del 20% de las ventas. Las de unidades son rangos fijos, porque el 62% de las ventas son de una sola pieza.

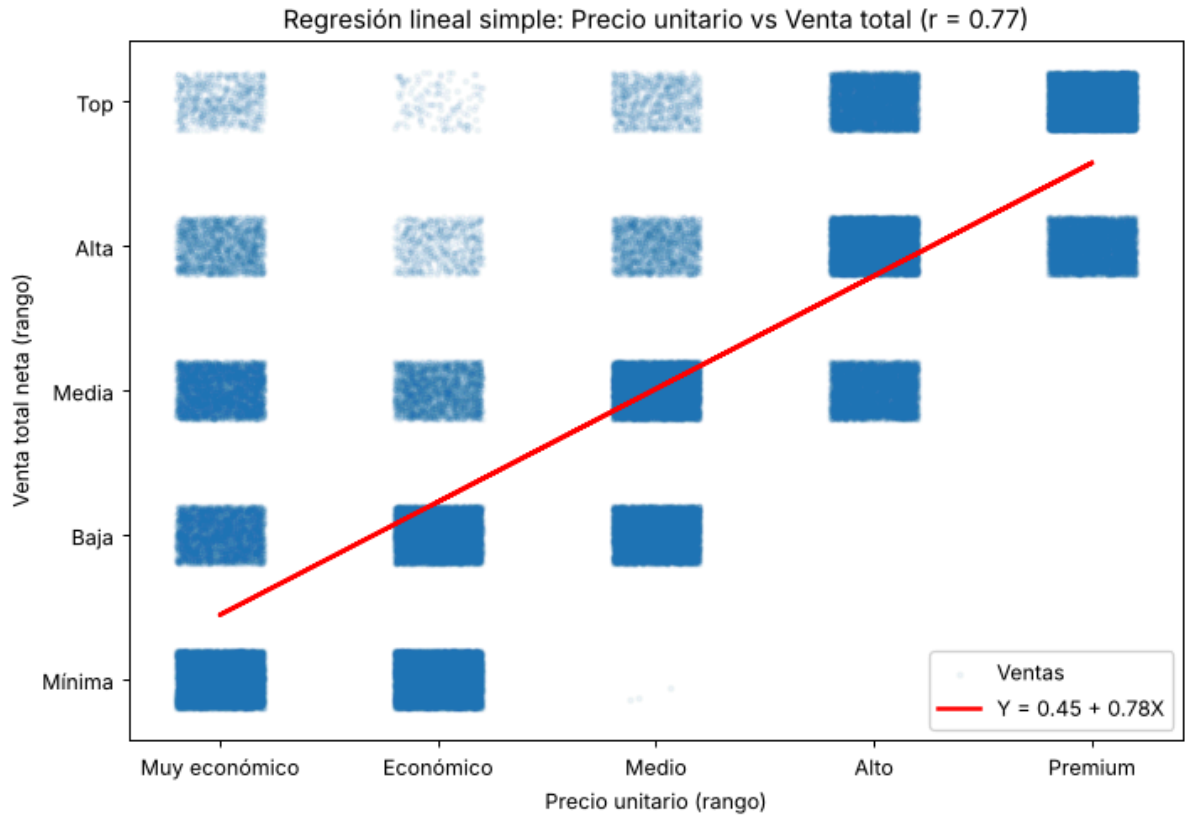
Regresión lineal simple



La mayor correlación está entre **precio unitario y venta total (r = 0.77)**.

Modelo: Venta total = 0.45 + 0.78 × Precio unitario (R^2 = 0.59)

- Por cada nivel que sube el precio, la venta total sube 0.78 niveles.
- El precio explica el 59% de la variación de la venta total.



¿Por qué se relacionan?

- La venta total es precio × unidades, y el 62% de las ventas son de una sola pieza. En esos casos el total es igual al precio.
- La relación no es perfecta porque las unidades también cuentan: los consumibles baratos se compran en volumen y los equipos caros de uno en uno (r = -0.19 entre precio y unidades).
- El año y el mes no se relacionan con la venta (r ≈ 0).

Regresión lineal múltiple

Y	X1 + X2	R^2 simple	R^2 múltiple
Venta total	Precio + Unidades	0.59	**0.84**
Precio unitario	Venta total + Unidades	0.59	0.82

Unidades	Venta total + Precio	0.11	0.62
Año	Mes + Unidades	0.02	0.02
Mes	Año + Venta total	0.02	0.02

Mejor modelo: Venta total = -0.24 + 0.88 × Precio + 0.74 × Unidades ($R^2 = 0.84$)

Comparación con el modelo simple (heatmap)

- Al agregar las unidades, el modelo de la venta total pasa de explicar el 59% al 84%.
- Los coeficientes suben en el modelo múltiple: el del precio pasa de 0.78 a 0.88 y el de las unidades, de 0.50 a 0.74. Por separado, el efecto de cada variable se esconde, porque los productos caros se venden en pocas piezas.
- El año y el mes no mejoran: si no hay relación de fondo, agregar variables no ayuda.

Conclusión

El monto de una venta depende de dos cosas: **qué se vende (precio) y cuánto se vende (unidades)**. Solo con el precio se explica el 59% de la venta total. Con precio y unidades juntos, el 84%. La fecha no influye: ni el año ni el mes cambian el tamaño de una venta.

El heatmap muestra que el negocio funciona con dos tipos de venta que se compensan:

- **Equipo de alto valor** (escáneres, hornos, kits): precio alto, una pieza por venta y ticket alto.
- **Consumibles** (dientes, fresas, bloques): precio bajo, venta por volumen. Llegan a un ticket alto solo cuando se compran en cantidad.

Por eso, el modelo múltiple da más peso al precio y a las unidades que el modelo simple: cada variable, sola, esconde parte del efecto de la otra.

Implicaciones para el socio formador

1. **Para subir el ticket:** impulsar el equipo y los kits, que es lo que más mueve el total por venta.
2. **En consumibles:** promover compras por volumen (paquetes o precio de mayoreo), porque con el mismo precio, más unidades suben el total de forma importante.
3. **Para pronosticar ventas:** la fecha no sirve para estimar el monto de una venta individual. Hay que usar el tipo de producto y el volumen.

Base: Historico Compras

Este documento analiza la hoja de Historico_Compras, que prepara el archivo Datos_CLVI.csv y explora la relación lineal entre sus variables numéricas mediante un heatmap de correlación de Pearson. Los identificadores (folio, articulo_id, clave_articulo) se excluyen del análisis, lo cual es correcto porque no representan magnitudes. Las variables evaluadas son unidades, precio_unitario, precio_total_neto, año y mes. Destaca la fuerte asimetría de los precios: la media del precio unitario (8,120.19) es más de 18 veces su mediana (447.82), y el precio total máximo alcanza $18,372,392.77 frente a una mediana de $5,848.56.

Resultados del heatmap

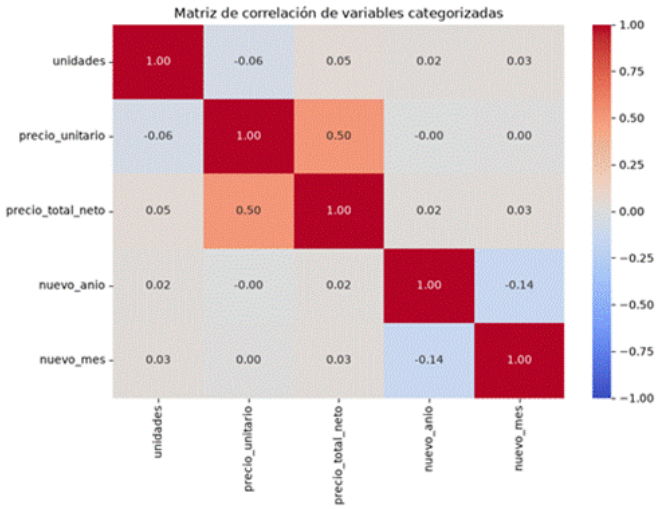


Figura 1. Heatmap de la matriz de correlación de las variables analizadas.

Descubrimiento principal. La única correlación relevante es la de *precio_unitario* con *precio_total_neto* (r = 0.50), que el código selecciona automáticamente como la pareja de mayor valor absoluto. Las demás relaciones son prácticamente nulas: unidades–precio unitario (-0.06), unidades–precio total (0.05), año–mes (-0.14) y todas las que involucran año o mes con las variables económicas (entre 0.00 y 0.03).

Posibles causas de las correlaciones

Precio unitario y precio total (r = 0.50)

La causa principal es aritmética: el total de una partida es, en esencia, unidades por precio unitario, por lo que al subir el precio sube el total. Esto es evidente en las partidas de una sola pieza, donde ambos valores coinciden (por ejemplo, 1 pieza a $77,289.56 con total de $77,289.56). Sin embargo, la correlación es solo moderada por tres razones:

- **La cantidad modifica la relación.** Las unidades van de 1 a 3,000: una fresa de unos $577 vendida en 400 piezas genera cerca de $230,944, más que un equipo de $77,289 vendido por pieza.
- **Coexisten dos tipos de partidas.** Por los nombres de artículo, parece haber equipos de alto valor vendidos casi siempre por pieza y consumibles baratos

vendidos en volumen. Es una hipótesis razonable, aunque el notebook no la comprueba directamente.

- **Valores extremos.** Pocas partidas con precios mayores a $1 millón dominan la covarianza, y Pearson es muy sensible a los atípicos.

Unidades frente a precios (r = -0.06 y 0.05)

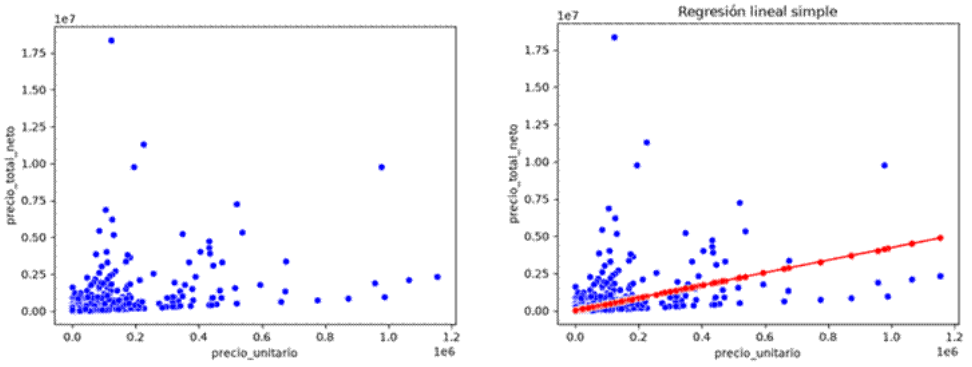
El signo ligeramente negativo entre unidades y precio unitario es coherente con la lógica comercial: lo caro se compra en pocas piezas y lo barato en grandes volúmenes. Ese mismo efecto explica que las unidades casi no se correlacionen con el total, a pesar de formar parte de su cálculo: ambos factores se compensan. Además, la relación unidades–total es multiplicativa y Pearson solo mide linealidad.

Año y mes

La ausencia de correlación con precios y volúmenes indica que no hay una tendencia temporal lineal clara. El valor de -0.14 entre año y mes probablemente es un efecto de la cobertura de los datos (el último año termina en septiembre y queda incompleto) y no un fenómeno comercial.

Regresión lineal simple

El código ajusta una regresión con precio_unitario como variable independiente y precio_total_neto como dependiente (Figuras 2 y 3). Se obtiene una pendiente de 4.20, un intercepto de $29,518.13 y un R^2 = 0.2511, que coincide con 0.5011^2, como corresponde a una regresión simple. Es decir, el precio unitario explica solo una cuarta parte de la variabilidad del total; el resto depende sobre todo de la cantidad vendida. La pendiente, mayor que 1, está muy influida por los valores extremos y no debe leerse como un efecto causal.

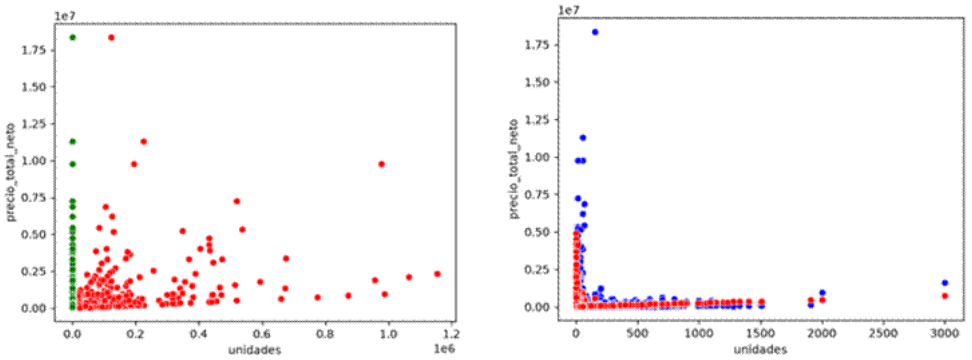


Figuras 2 y 3. Dispersión entre precio unitario y precio total (izquierda) y regresión lineal simple con valores reales y predichos (derecha).

Regresión lineal múltiple

Con el fin de mejorar la explicación del precio total, el notebook amplía el modelo anterior e incorpora cuatro variables independientes: unidades, precio_unitario, nuevo_anio y nuevo_mes. La Figura 4 muestra la dispersión de cada una frente al precio total y la Figura 5 compara los valores reales (azul) con los predichos (rojo) respecto a las unidades. La Figura 4 coloca las cuatro variables sobre un mismo eje horizontal, por lo que sus escalas

(miles de unidades, años, meses) no son comparables entre sí y sirve solo como apoyo visual.



Figuras 4 y 5. Dispersión de las variables independientes frente al precio total (izquierda) y valores reales y predichos según las unidades (derecha).

La ecuación obtenida es: precio_total_neto = -10,854,370.36 + 246.57(unidades) + 4.24(precio_unitario) + 5,364.46(nuevo_anio) + 2,736.61(nuevo_mes). El coeficiente de determinación es $R^2 = 0.2578$ y el de correlación múltiple $R = 0.5078$.

Descubrimientos.

1. El R^2 solo aumenta de 0.2511 a 0.2578 (0.67 puntos porcentuales) al pasar de una a cuatro variables, de modo que el modelo múltiple casi no mejora al simple y sigue sin explicar cerca del 74 % de la variabilidad.
2. El precio unitario conserva prácticamente el mismo coeficiente (4.24 frente a 4.20), lo que confirma que es la variable dominante.
3. Cada unidad adicional aporta sólo $246.57, un valor bajo frente a un precio medio de 8,120; es se debe a que el modelo es aditivo y no representa la relación multiplicativa entre cantidad y precio, además de su relación inversa.
4. Los coeficientes de año y mes son positivos, pero sus correlaciones con el total son casi nulas (0.02 y 0.03), por lo que su aporte es marginal y no debe leerse como una tendencia real; el notebook tampoco calcula pruebas de significancia.
5. El intercepto de -10.85 millones no tiene interpretación práctica: resulta de extrapolar al año 0 (5,364.46 × 2,021 ≈ $10.84 millones) y compensa el efecto del año.

Las predicciones muestran el límite del modelo: para la primera partida (1 pieza a $77,289.56) estima $323,149.75 contra un real de $77,289.56, mientras que para una de 400 piezas a $577.36 estima $139,729.18 frente a un real de $230,943.96. Sobreestima los equipos caros de una pieza y subestima los consumibles de volumen, lo que coincide con la hipótesis de dos tipos de partidas. Además, el R^2 se calcula con los mismos datos del ajuste, sin partición de entrenamiento y prueba.

Limitaciones y recomendaciones

- El heatmap se titula «variables categorizadas» pero usa variables numéricas, y un comentario indica que se predice con «unidades» cuando el modelo usa precio_unitario.
- Año y mes son ordinales o cíclicos, por lo que Pearson no es el indicador más adecuado para ellos.

- Conviene probar una transformación logarítmica de los precios, la correlación de Spearman un término de interacción entre unidades y precio unitario (o modelar el logaritmo del total) y validar con partición de entrenamiento y prueba; es probable que mejoren el ajuste, aunque debe verificarse con los datos.

Conclusión

El heatmap muestra que la relación lineal más fuerte del conjunto es la del precio unitario con el precio total neto (r = 0.50), explicada por la estructura de cálculo del total pero debilitada por la cantidad vendida, el tipo de artículo y los valores extremos. El resto de las variables aporta muy poca información lineal. La regresión simple ($R^2 = 0.2511$) y la múltiple ($R^2 = 0.2578$) explican poco más de una cuarta parte del total, y agregar unidades, año y mes casi no mejora el ajuste. Un análisis con transformaciones, interacciones y validación daría resultados más sólidos.

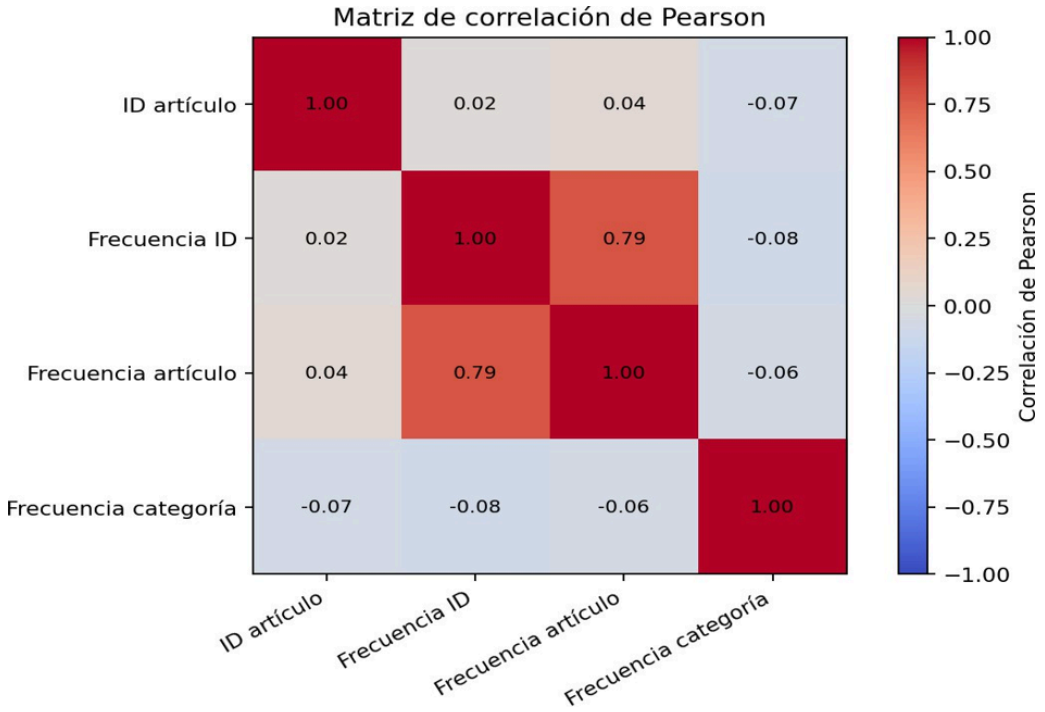
Base de datos: Clasificación_articulos

El conjunto de datos dispone de 18,322 filas y tres campos iniciales: *articulo_ID*, *nombre_articulo* y *categoria*. Tras el procesamiento, se detectaron 5,431 identificadores únicos, 5,472 descripciones de producto y 153 clasificaciones operativas. Para habilitar los modelos de regresión, se generaron métricas de frecuencia asociadas a cada código, descripción y categoría.

Variable	Tipo	Rol en el análisis
articulo_ID	Identificador numérico	Predictor exploratorio; no es una magnitud continua real.
frecuencia_Id	Conteo discreto	Número de registros que comparten el mismo ID.
frecuencia_articulo	Conteo discreto	Número de apariciones de cada nombre de artículo; objetos y predictor.
frecuencia_categoria	Conteo discreto	Número de apariciones de cada categoría; objetivos y predictor.

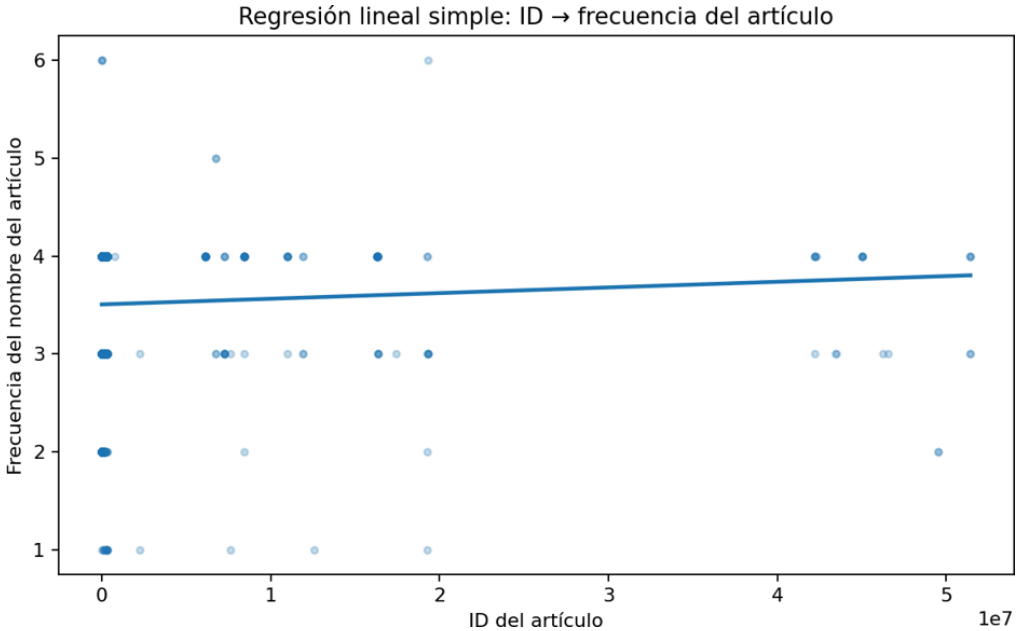
Se normalizaron los nombres de las columnas eliminando espacios laterales y se convirtió el ID a formato numérico. Las variables de frecuencia se calcularon mediante conteos por grupo, conservando las filas originales. Es importante señalar que un ID es una etiqueta identificadora: la distancia entre IDs no tiene por qué representar distancia o magnitud. Por tanto, cualquier asociación entre el ID y las frecuencias debe leerse sólo como exploratoria.

Resultados del Heatmap



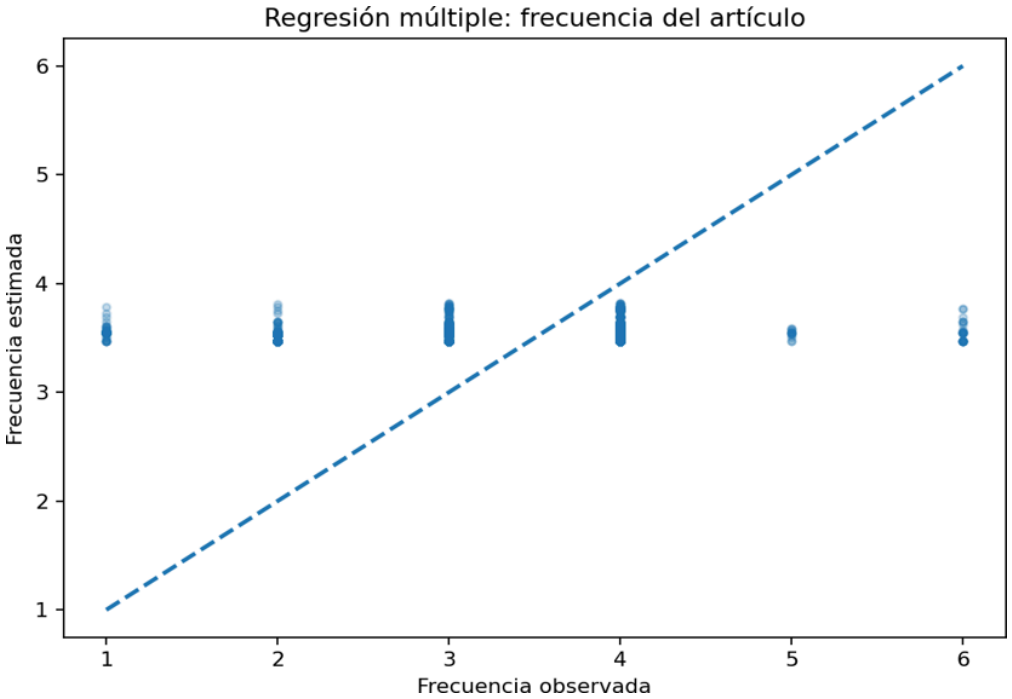
La matriz utiliza correlación de Pearson para resumir la asociación lineal entre las variables numéricas derivadas. Las correlaciones de frecuencias deben interpretarse con cautela porque las variables se construyeron a partir de las mismas etiquetas y observaciones; no prueban causalidad.

Regresión lineal simple



El modelo simple ilustrado estima la frecuencia del nombre del artículo a partir del ID. La recta describe el ajuste lineal promedio, pero no implica que el identificador tenga un efecto real sobre la frecuencia. La dispersión muestra la variabilidad de frecuencias para distintos IDs.

Regresión lineal múltiple



El modelo múltiple principal utiliza el ID y la frecuencia de la categoría para estimar la frecuencia del nombre del artículo. La gráfica compara valores observados con estimaciones: los puntos más cercanos a la diagonal representan predicciones más próximas al valor observado.

Resultados de los modelos

Modelo	Objetivo	Predictores	R^2	RMSE
Simple A: ID fi frecuencia del artículo	frecuencia_articulo	articulo_ID	0.002	0.64
Simple B: ID fi frecuencia de la categoría	frecuencia_categoria	articulo_ID	0.005	1857.52
Simple C: frecuencia del artículo fi frecuencia de la categoría	frecuencia_categoria	frecuencia_articulo	0.003	1858.63
Múltiple A: frecuencia del artículo frecuencia_articulo	frecuencia_articulo	articulo_ID, frecuencia_categoria	0.005	0.64
Múltiple B: frecuencia de la categoría	frecuencia_categoria	articulo_ID, frecuencia_articulo	0.008	1854.62

Ecuaciones estimadas

Simple A: ID -> **frecuencia del artículo**: frecuencia_articulo = 3.5061 + 0.000000·articulo_ID. R^2 = 0.0016; n = 18,322.

Simple B: ID -> **frecuencia de la categoría**: frecuencia_categoria = 2289.9347 - 0.000028·articulo_ID. R^2 = 0.0046; n = 18,322.

Simple C: frecuencia del artículo -> **frecuencia de la categoría**: frecuencia_categoria = 2860.3410 - 168.866629·frecuencia_articulo. R^2 = 0.0034; n = 18,322.

Múltiple A: frecuencia del artículo: frecuencia_articulo = 3.5504 + 0.000000·articulo_ID - 0.000019·frecuencia_categoria. R^2 = 0.0047; n = 18,322.

Múltiple B: frecuencia de la categoría: frecuencia_categoria = 2855.4633 - 0.000027·articulo_ID - 161.299499·frecuencia_articulo. R^2 = 0.0077; n = 18,322.

Conclusión y limitaciones

Este análisis representa un primer acercamiento al uso de herramientas de analítica de datos para explorar información y apoyar la toma de decisiones empresariales. Mediante el análisis de frecuencias, correlaciones y modelos de regresión, fue posible identificar patrones en los registros y comprender algunas de las posibilidades y limitaciones de los datos disponibles.

Sin embargo, los resultados obtenidos no constituyen todavía un sistema predictivo confiable, ya que el identificador (ID) no es una variable explicativa relevante y las frecuencias calculadas podrían generar filtraciones de información. Además, la frecuencia de aparición de un producto no equivale necesariamente a su demanda real. Para desarrollar análisis más útiles para la gestión del inventario, sería necesario incorporar datos de ventas, existencias, costos y fechas, así como definir una variable objetivo adecuada y evaluar los modelos con datos de entrenamiento y prueba. Así, este ejercicio establece una base para futuros análisis con mayor aplicación empresarial.